tidyverse优雅的处理数据

R数据分析指南-闫俊安

2021-10-19

目录

- 引言
 - 。 tidyverse家族
- 数据处理
 - 。 1. 宽表转长表
 - 1.1 pivot_longer函数
 - 。 2. 长表转宽表
 - 2.1 pivot_wider函数
 - 。 3. select选择列的方法
 - 3.1 select选择列基础
 - 3.2 根据部分列名选择列
 - 3.3 根据正则表达式选择列
 - 3.4 根据数据集来选择列
 - 3.5 按数据类型选择列 (重点)
 - 3.6 通过逻辑表达式选择列 (重点)
 - 3.7 对列进行重新排序
 - 3.8 更改列名
 - 3.9 重新格式化所有列名
 - 3.10 自主创建函数(重点)
 - 3.11 从行到列
 - 。 4. filter按行处理数据
 - 4.1 基本行过滤
 - 4.2 根据多个条件进行筛选
 - 4.3 重点xor
 - 4.4 多条件嵌套过滤
 - 4.5 跨多列过滤
 - 4.5.1 filter_all()
 - 4.5.2 filter_if()
 - 4.5.3 filter at()
 - 5. mutate创建新列
 - 5.1 mutate 基础操作
 - 5.2 对多列同时进行操作
 - 5.2.1 将所有数据转换为小写:
 - 5.2.2 所有列添加″/n ″
 - 5.2.3 将″/n ″全部替换为空
 - 5.3 mutate_if()对数据进行判断
 - 5.4 mutate_at()对特定列进行操作
 - 5.5 更改列名
 - 5.6 ifelse创建2个级别的离散列
 - 5.7 case_when创建多级离散列
 - 5.8 将数据转化为NA
 - ∘ 6. rowwise行处理函数
 - 6.1 按行计算均值
 - 6.2 按行统计最小值
 - 6.3 按行统计最大值
 - 6.4 按行求和

- 6.5 按行计算标准差
- 6.6 统计每行中某值出现的次数
- ∘ 7. tidyverse中的专职函数(上)
 - 7.1 arrange()排序
 - 7.2 desc()数据降序
 - 7.3 distinct()数据去重
 - 7.4 rename()更改列名
 - 7.5 relocate()更改列顺序
 - 7.5.1 指定列的顺序
 - 7.5.2 移至最后一列
 - 7.5.3 选择所有字符列
 - 7.5.4 选择所有数字列
 - 7.6 dorp_na()删除缺失值
 - 7.7 pull()提取单列
 - 7.7.1 点过滤
- 8. tidyverse中的专职函数(中)
 - 8.1 unite多列合并
 - 8.1.1 unite结合for循环合并多列
 - 8.2 sperate拆分列
 - 8.2.1 只取分隔符前的列
 - 8.2.2 多列进行拆分
 - 8.3 sparate_rows将折叠的行展开
 - 8.3.1 for循环展开多列
- 。 9. tidyverse中的专职函数(下)
 - 9.1 bind_rows数据框纵向合并
 - 9.2 bind_cols横向合并数据框
 - 9.3 inner_join 内部连接
- 10. across()列处理函数
 - 10.1 给每一列加1
 - 10.2 前两列四舍五入
 - 10.3 按列求均值
 - 10.4 按行求和
 - 10.5 分组求均值
 - 10.6 分组求和
 - 10.7 使用.name参数控制输出名
 - 10.8 筛选没有缺失值的行
 - 10.9 统计字符长度
 - 10.10 统计列最小/最大值
- ∘ 11. summarise汇总数据
 - 11.1 count()
 - 11.2 summarize()
 - 11.3 group_by()按分组进行汇总
 - 11.4 summarise_all()
 - 11.5 summarise_if()
 - 11.6 rename_if()对列进行重命名
 - 11.7 summarise_at()
 - 11.8 top_n()
 - 11.9 sample_frac()

引言

本文档主要介绍tidyverse体系在数据分析中的一些常见的使用方法,使用tidyverse可以很轻松的完成从数据清洗到数据可视化一整套的分析流程,即数据导入、格式转化、数据清洗、数据可视化、统计建模以及使用Rmarkdown生成分析报告,整个数据分析及可视乎都在一个程序代码中完成,这种方式使的数据分析过程变得异常简洁



tidyverse家族



tidyverse家族核心成员

功能	R包
数据可视化	ggplot2
数据处理	dplyr
格式转换	tidyr
数据加载	readr
循环加速	purrr
数据框强化	tibble
字符串处理	stringr
因子处理	forcats

数据处理

现在我们正式开始数据处理的历程,主要介绍tidyverse中的一些常用函数,并通过一个个小案例来进行系统性的展示



1. 宽表转长表

1.1 pivot_longer函数

如果您是R语言的初学者,在开始进行数据格式转换前请先阅读以下2篇文档

配置R与Rstudio

ggplot2中的一些关键概念

通过上面2篇文档的学习,相信您已经了解了如何安装 R 包,设置路径以及对 ggplot2 的一些关键概念有了了解,下面就该读入自己的数据来进行可视化了;那么在画图之前我们还需要对数据来进行格式处理,是否还记得在 ggplot2 进行可视化时需要给 aes 传入2个美学参数,一个作为X另一个为Y,但是我们通常手里边的数据有很多列,在R中将其定义为宽表,而 ggplot 函数需要的数据格式在R中我们定义为长表,因此第一步即**宽表转长表**

如下图所示

wide				long		
id	Х	у	Z	id	key	val
1	a	С	е	1	Х	a
2	b	d	f	2	Х	b
				1	у	С
				2	у	d
				1	Z	е
				2	Z	f

下面我们创建数据集来演示一下

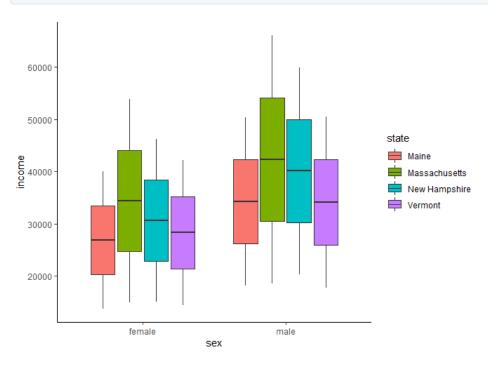
```
## state male_fulltime male_other female_fulltime female_other
## 1 Maine 50329 18099 40054 13781
## 2 Massachusetts 66066 18574 53841 14981
## 3 New Hampshire 59962 20274 46178 15121
## 4 Vermont 50530 17709 42198 14422
```

可以看到通过pivot_longer()函数很轻松完成了宽表转长表

- pivot_longer()函数有三个主要的参数
- cols,表示哪些列需要转换
- names_to,表示cols选取的这些列的名字,构成了新的一列或多列;需要给定名称
- values_to,表示cols选取的这些列的值,构成了新的一列,同样要给定名称

经过上面的格式转换我们得到了需要的数据,接下来进行一个简单的可视化

```
df2.long %>% ggplot(aes(sex,income,fill=state))+
  geom_boxplot()+theme_classic()
```



在某些时刻我们可能还需要进行长表转宽表,让我们通过下面的代码来学习

2. 长表转宽表

2.1 pivot_wider函数

```
## # A tibble: 4 x 5
## state male.fulltime male.other female.fulltime female.other
           <dbl> <dbl> <dbl> <dbl>
## <chr>
                  50329 18099
66066 18574
                                         40054
                                                   13781
## 1 Maine
## 2 Massachusetts
                                         53841
                                                   14981
                   59962 20274
50530 17709
                                        46178
## 3 New Hampshire
                                                   15121
                                         42198
                                                   14422
## 4 Vermont
```

3. select选择列的方法

3.1 select选择列基础

要选择几列,只需在select函数中添加其名称即可。添加它们的顺序将确定它们在输出中出现的顺序

```
msleep %>% select(name, genus, sleep_total, awake) %>% head()
```

```
## # A tibble: 6 x 4
                       genus sleep_total awake
## name
## <chr>
                        Acinonyx
## 1 Cheetah
                                      12.1 11.9
                        Actionyx
                                       17 7
## 2 Owl monkey
## 3 Mountain beaver Aplodontia 14.4 9.6
## 4 Greater short-tailed shrew Blarina 14.9 9.1
                         Bos
                                        4 20
                        Bradypus 14.4 9.6
## 6 Three-toed sloth
```

如果要添加大量的列,可以使用start col:end col的语句:

```
msleep %>% select(name:order,sleep_cycle:brainwt) %>% head()
```

还可以通过在列名称前面添加减号来取消列

```
msleep %>% select(-conservation, -(sleep_total:awake)) %>% head()
```

```
## 4 Greater short-tailed shrew Blarina omni Soricomorpha 0.00029 0.019
## 5 Cow Bos herbi Artiodactyla 0.423 600
## 6 Three-toed sloth Bradypus herbi Pilosa NA 3.85
```

3.2 根据部分列名选择列

如果有很多的列具有相似的结构,可以通过starts_with(),ends_with()或contains()来进行选择

```
msleep %>% select(name, starts_with("sleep")) %>% head()
```

```
## # A tibble: 6 x 4
## name
                        sleep_total sleep_rem sleep_cycle
                           ## <chr>
                              12.1 NA
                                              NA
## 1 Cheetah
                                             NA
                                     1.8
                             17
## 2 Owl monkey
                             14.4 2.4
14.9 2.3
4 0.7
## 3 Mountain beaver
                                             NA
## 4 Greater short-tailed shrew
                                              0.133
                             4 0.7 0.667
14.4 2.2 0.767
## 5 Cow
## 6 Three-toed sloth
```

```
msleep %>% select(contains("eep"), ends_with("wt")) %>% head()
```

3.3 根据正则表达式选择列

如果列名没有相似性,则可以使用matches()来进行选择;以下示例代码将添加包含"o"后跟一个或多个其他字母和"er"的列

```
msleep %>% select(matches("o.+er")) %>% head()
```

3.4 根据数据集来选择列

```
class <- c("name", "genus", "vore", "order", "conservation")
msleep %>% select(!!class) %>% head()
```

```
## # A tibble: 6 x 5
## name genus vore order conservation
```

3.5 按数据类型选择列(重点)

select_if()函数来判断数据类型,可以使用其来选择所有字符串列select_if(is.character)。同样也可以添加 is.numeric,is.integer,is.double,is.logical,is.factor等列;如果有日期列,则可以加载lubridate包,然后使用 is.POSIXt 或is.Date来进行格式转换

```
msleep %>% select_if(is.numeric) %>% head()
```

同样也可以取反,选择不需要那种数据类型的列

```
msleep %>% select_if(~!is.numeric(.)) %>% head()
```

```
## # A tibble: 6 x 5
## name
                           genus vore order 
<chr> <chr> <chr>
                                                       conservation
## <chr>
                                                        <chr>
## 1 Cheetah
                           Acinonyx carni Carnivora lc
## 2 Owl monkey Aotus omni Primates
## 3 Mountain beaver Aplodontia herbi Rodentia
                                       omni Primates
                                                        <NA>
## 4 Greater short-tailed shrew Blarina omni Soricomorpha lc
## 5 Cow
                      Bos herbi Artiodactyla domesticated
                       Bradypus herbi Pilosa <NA>
## 6 Three-toed sloth
```

3.6 通过逻辑表达式选择列 (重点)

select_if()不仅仅是基于数据类型来进行选择。还可以选择所有列平均值大于10的列。mean > 10它本身不是函数,因此需要在前面添加波浪号,或使用funs()将语句转换为函数

```
msleep %>% select_if(is.numeric) %>%
select_if(~mean(., na.rm=TRUE) > 10) %>% head()
```

```
msleep %>%
select_if(~is.numeric(.) & mean(., na.rm=TRUE) > 10) %>% head()
```

另一个有用的select_if参数是n_distinct(),它可以在列中找到的不同值出现的数量

```
msleep %>% select_if(~n_distinct(.) < 10) %>% head()
```

```
## # A tibble: 6 x 2
## vore conservation
## <chr> <chr> <chr> ## 1 carni lc
## 2 omni <NA>
## 3 herbi nt
## 4 omni lc
## 5 herbi domesticated
## 6 herbi <NA>
```

3.7 对列进行重新排序

everything()函数可将选择的列移至表格最前

```
msleep %>% select(conservation, sleep_total, everything()) %>% head()
```

3.8 更改列名

```
msleep %>%
select(animal = name, sleep_total, extinction_threat = conservation)
```

```
## 4 Greater short-tailed shrew
## 5 Cow
## 6 Three-toed sloth
## 7 Northern fur seal
## 8 Vesper mouse
## 9 Dog
## 10 Roe deer
## # ... with 73 more rows

14.9 lc
# domesticated
## 4... with 73 more rows

14.9 lc
# domesticated
## 10 Roe deer
## 10 Roe deer
## # ... with 73 more rows
```

也可以通过rename()函数来重命名

```
msleep %>%
  rename(animal = name, extinction_threat = conservation)
```

```
## # A tibble: 83 x 11
## animal genus vore order extinction_thre~ sleep_total sleep_rem sleep_cycle
## <chr> <chr> <chr> <chr> <chr> <chr> <dbl> <dbl> <dbl>
## 1 Cheetah Acin~ carni Carn~ lc
                                                      12.1
                                                               NA
                                                                          NΑ
                                                      17
                                                                 1.8
                                                                          NA
## 2 Owl mon~ Aotus omni Prim~ <NA>
## 3 Mountai~ Aplo~ herbi Rode~ nt
## 4 Greater~ Blar~ omni Sori~ lc
## 5 Cow Bos herbi Arti~ domesticated
                                                      14.4
                                                                 2.4
                                                    14.9 2.3 0.13
4 0.7 0.66
14.4 2.2 0.76
8.7 1.4 0.38
7 NA NA
                                                                 2.3
                                                                         0.133
                                                                          0.667
## 6 Three-t~ Brad~ herbi Pilo~ <NA>
                                                                          0.767
## 7 Norther~ Call~ carni Carn~ vu
                                                                          0.383
## 8 Vesper ~ Calo~ <NA> Rode~ <NA>
## 9 Dog Canis carni Carn~ domesticated 10.1 2.9
## 10 Roe deer Capr~ herbi Arti~ lc 3 NA
                                                                 2.9
                                                                           0.333
                                                                       NA
## # ... with 73 more rows, and 3 more variables: awake <dbl>, brainwt <dbl>,
## # bodywt <dbl>
```

3.9 重新格式化所有列名

select_all()函数允许更改所有列,并以一个函数作为参数。要以大写形式获取所有列名称,可以使用toupper(),也可以使用tolower()将其全部转化为小写

```
msleep %>% select_all(toupper) %>% head()
```

3.10 自主创建函数(重点)

将列名中的空格替换为下划线

```
msleep2 <- select(msleep, name, sleep_total, brainwt)
colnames(msleep2) <- c("name", "sleep total", "brain weight")
msleep2 %>% select_all(~str_replace(., " ", "_"))
```

```
## # A tibble: 83 x 3
## name sleep_total brain_weight
```

还可以使用select_all与str_replace来消除多余的字符

```
msleep2 <- select(msleep, name, sleep_total, brainwt)
colnames(msleep2) <- c("Q1 name", "Q2 sleep total", "Q3 brain weight")
msleep2[1:3,]</pre>
```

```
msleep2 %>%
  select_all(~str_replace(., "Q[0-9]+", "")) %>%
  select_all(~str_replace(., " ", "_"))
```

```
## # A tibble: 83 x 3
## `_name`
                         `_sleep total` `_brain weight`
                                  ##
    <chr>
                                           NA
                                  12.1
## 1 Cheetah
## 2 Owl monkey
                                  17
                                            0.0155
                                  14.4
## 3 Mountain beaver
                                           NA
## 4 Greater short-tailed shrew
                                 14.9
                                            0.00029
                                0.42
14.4 NA
8.7 NA
7 NA
10.1 0.07
3
                                            0.423
## 5 Cow
## 6 Three-toed sloth
## 7 Northern fur seal
## 8 Vesper mouse
## 9 Dog
                                            0.0982
## 10 Roe deer
## # ... with 73 more rows
```

3.11 从行到列

某些数据框的行名本身实际上并不是一列,例如mtcars数据集

```
        mpg cyl disp
        hp drat
        wt qsec vs am gear carb

        Mazda RX4
        21.0
        6
        160
        110
        3.90
        2.620
        16.46
        0
        1
        4
        4

        Mazda RX4 Wag
        21.0
        6
        160
        110
        3.90
        2.875
        17.02
        0
        1
        4
        4

        Datsun 710
        22.8
        4
        108
        93
        3.85
        2.320
        18.61
        1
        1
        4
        1

        Hornet 4 Drive
        21.4
        6
        258
        110
        3.08
        3.215
        19.44
        1
        0
        3
        1

        Hornet Sportabout
        18.7
        8
        360
        175
        3.15
        3.440
        17.02
        0
        0
        3
        2

        Valiant
        18.1
        6
        225
        105
        2.76
        3.460
        20.22
        1
        0
        3
        1
```

```
mtcars %>%
  tibble::rownames_to_column("car_model") %>% head
```

4. filter按行处理数据

还是使用我们熟悉的iris(鸢尾花)数据集,可以看到数据有5列,150行,数据类型为数据框;分别表示 Sepal.Length(花萼长度),Sepal.Width(花萼宽度)、Petal.Length(花瓣长度),Petal.Width(花瓣宽度)、 Species(花的类型),其中花有3种类型(setosa、versicolor、virginica)

```
iris %>% as_tibble() %>% head()
```

4.1 基本行过滤

筛选出含有setosa的行,注意是 ==

```
iris %>% as_tibble() %>% filter(Species=="setosa") %>% head()
```

筛选出不含有setosa的行, R中!= 代表不等于

```
iris %>% as_tibble() %>% filter(Species !="setosa") %>% head()
```

```
## 5 6.5 2.8 4.6 1.5 versicolor
## 6 5.7 2.8 4.5 1.3 versicolor
```

```
# 此2种方法结果一致,处理复杂数据时推荐第二种
iris %>% as_tibble() %>% filter(!Species %in% "setosa") %>% head()
```

根据2个关键词进行筛选 通过 %in% 进行判断

```
iris %>% as_tibble() %>%
filter(.,Species %in% c("setosa","virginica")) %>% head()
```

```
## # A tibble: 6 x 5
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
    <dbl> <dbl> <dbl> <dbl> <fct>
                           0.2 setosa
1.4 0.2
                3.5 1.4
3 1.4
## 1
         5.1
         4.9
        4.9
4.7 3.2
4.6 3.1
3.6
## 2
                 3
                 3.2
                                 0.2 setosa0.2 setosa0.2 setosa
## 3
                           1.3
## 4
                           1.5
## 5
                           1.4
## 6 5.4 3.9 1.7 0.4 setosa
```

!Species 表示不包含在其中,此处注意前面的.,

```
iris %>% as_tibble() %>%
filter(.,!Species %in% c("setosa","virginica")) %>% head()
```

4.2 根据多个条件进行筛选

- filter(condition1, condition2) 将返回同时满足两个条件的行
- filter(condition1, !condition2) 将返回条件一为真但条件二为不成立的所有行
- filter(condition1 | condition2) 将返回满足条件1和/或条件2的行
- filter(xor(condition1, condition2)将返回仅满足一个条件的所有行,而不是同时满足两个条件的所有行

```
iris %>% as_tibble() %>%
filter(Species=="setosa", Sepal.Length >= 5) %>% head()
```

& 在R中表示和的意思与,作用一致; | 或的意思

```
iris %>% as_tibble() %>%
filter(.,(Species=="setosa" & !Sepal.Length >= 5)) %>% head()
```

```
iris %>% as_tibble() %>%
filter(.,(Species=="setosa" | Sepal.Length >= 5)) %>% head()
```

4.3 重点xor

xor只返回仅满足一个条件的所有行,而不是同时满足两个条件的所有行即 c(T,F) | c(F,T) 2种情况

```
iris %>% as_tibble() %>%
filter(.,xor(Species=="setosa",Sepal.Length >= 5)) %>% head()
```

```
iris %>% as_tibble() %>%
filter(.,(Species=="setosa" & !Sepal.Length >= 5)) %>% head()
```

```
iris %>% as_tibble() %>%
filter(.,Species!= "setosa",Sepal.Length >= 5) %>% head()
```

4.4 多条件嵌套过滤

此代码将首先提取出含有 setosa 的行,之后根据 Sepal. Length >= 5 这一条件对其进行过滤,最后将含有 versicolor", "virginica" 的数据追加上去

```
iris %>% as_tibble() %>%
filter(.,(Species=="setosa" & Sepal.Length >= 5)|(Species %in% c("versicolor","virginica")))
```

```
## # A tibble: 130 x 5
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
                <dbl> <dbl> <dbl> <fct>

      5.1
      3.5
      1.4
      0.2 setosa

      5
      3.6
      1.4
      0.2 setosa

      5.4
      3.9
      1.7
      0.4 setosa

      5
      3.4
      1.5
      0.2 setosa

      5.4
      3.7
      1.5
      0.2 setosa

      5.8
      4
      1.2
      0.2 setosa

      5.7
      4.4
      1.5
      0.4 setosa

      5.4
      3.9
      1.3
      0.4 setosa

      5.1
      3.5
      1.4
      0.3 setosa

      1.7
      0.3 setosa

## 1
## 2
## 3
## 4
## 5
## 6
## 7
## 8
## 9
                5.7 3.8
## 10
## # ... with 120 more rows
```

删除Species中含有 NA 的行

```
iris %>% filter(!is.na(Species)) %>% head()
```

```
## 4 4.6 3.1 1.5 0.2 setosa
## 5 5.0 3.6 1.4 0.2 setosa
## 6 5.4 3.9 1.7 0.4 setosa
```

4.5 跨多列过滤

- filter all() 过滤所有列
- filter_if()需要一个返回的布尔值以指示要过滤列的类型。如果是符合条件则将遵循这些列进行过滤
- filter_at()要求在vars()参数中指定要进行过滤的列

4.5.1 filter all()

对数值执行全部筛选: 此代码将保留任何值等于5的行

```
iris %>% filter_all(any_vars(. == 5)) %>% head()
```

```
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1
    5 3.6 1.4 0.2 setosa
          5
                          1.5
                3.4
## 2
                                  0.2 setosa
               3.0
3.4
3.2
3.5
## 3
         5
                         1.6
                                 0.2 setosa
         5
                         1.6
                                 0.4 setosa
         5
                         1.2
                                 0.2 setosa
## 5
                                  0.3 setosa
         5
                         1.3
## 6
```

对字符串进行过滤,在所有列中检索含有"Ca"的字符串,需要将条件包装在any_vars()中

```
msleep %>%
select(name:order, sleep_total, -vore) %>%
filter_all(any_vars(str_detect(., pattern = "Ca"))) %>% head()
```

4.5.2 filter if()

下面这段代码首先对列的类型进行判断,再在字符列中筛选 NA

```
msleep %>%
select(name:order, sleep_total:sleep_rem) %>%
filter_if(is.character, any_vars(is.na(.))) %>% head()
```

4.5.3 filter_at()

filter_at()它不筛选所有列,也不需要您指定列的类型,可以通过vars()参数选择要对那些列进行筛选

```
iris %>%
filter_at(vars(Sepal.Length,Petal.Length),all_vars(. >=6)) %>% head()
```

```
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1 6.3 3.3 6.0 2.5 virginica
## 2 7.6 3.0 6.6 2.1 virginica
## 3 7.3 2.9 6.3 1.8 virginica
## 4 7.2 3.6 6.1 2.5 virginica
## 5 7.7 3.8 6.7 2.2 virginica
## 6 7.7 2.6 6.9 2.3 virginica
```

5. mutate创建新列

mutate函数其基本功能为创建新列;mutate中的选项几乎是无穷无尽的,可以通过各种函数之间的组合来对数据集做任意的处理,下面通过具体的案例来进行演示

这次我们使用R内置的数据集msleep, 其中包括哺乳动物的睡眠时间。让我们首先加载包并查看数据:

```
msleep %>% as_tibble()
```

```
## # A tibble: 83 x 11

## name genus vore order conservation sleep_total sleep_rem sleep_cycle awake

## <chr>  <chr>                                                                                 </
```

5.1 mutate 基础操作

最简单的的操作就是根据其他列中的值进行计算。在示例代码中,我们将睡眠数据从以小时为单位更改为分钟为单位 位

```
msleep %>%
  select(name,sleep_total) %>%
  mutate(sleep_total_min = sleep_total * 60) %>% head()
```

```
## # A tibble: 6 x 3
## name
                     sleep total sleep total min
## <chr>
                       12.1
## 1 Cheetah
                                       726
## 2 Owl monkey
                          17
                                      1020
## 3 Mountain beaver
                          14.4
## 4 Greater short-tailed shrew
                          14.9
                                      894
                                       240
                           4
## 5 Cow
                                864
                          14.4
## 6 Three-toed sloth
```

下列代码创建了两列新列:一列显示了睡眠时间与平均睡眠时间的差异,另一列显示了与睡眠时间最少的动物之间的差异;**round**()对数据进行四舍五入操作

选择特定列按行求均值, rowwise()说明按行进行操作

```
msleep %>%
  select(name, contains("sleep")) %>%
  rowwise() %>%
  mutate(avg = mean(c(sleep_rem,sleep_cycle))) %>% head()
```

通过ifelse判断语句对数据进行操作,如果 brainwt > 4返回 NA,不满足此条件返回原值

```
msleep %>%
  select(name, brainwt) %>%
  mutate(brainwt2 = ifelse(brainwt > 4, NA, brainwt)) %>%
  arrange(desc(brainwt)) %>% head()
```

也可以结合使用stringr的功能或正则表达式来对字符串列进行操作:示例代码将返回动物名称的最后一个单词,并使 其小写

```
msleep %>%
select(name) %>%
```

```
mutate(name_last_word = tolower(str_extract(name, pattern = "\\w+$"))) %>% head()
```

5.2 对多列同时进行操作

- mutate_all() 将对所有列进行操作
- mutate_if()首先需要一个返回布尔值,如果是T,则将在这些变量上执行mutate指令
- mutate_at()要求在vars()参数内指定要进行改变的列

5.2.1 将所有数据转换为小写:

```
msleep %>% mutate_all(tolower) %>% head
```

5.2.2 所有列添加 " /n "

```
msleep %>% mutate_all(~paste(., " /n ")) %>% head()
```

5.2.3 将 " /n " 全部替换为空

```
msleep_ohno <- msleep %>% mutate_all(~paste(., " /n ")) %>% head()

msleep_ohno %>%
  mutate_all(~str_replace_all(., "/n", "")) %>%
  mutate_all(str_trim) %>% head()
```

5.3 mutate_if()对数据进行判断

如果数据类型是数值,对其进行四舍五入操作

```
msleep %>%
select(name, sleep_total:bodywt) %>%
mutate_if(is.numeric, round) %>% head()
```

5.4 mutate at()对特定列进行操作

对列名含有 sleep 的进行操作

```
msleep %>%
  select(name, sleep_total:awake) %>%
  mutate_at(vars(contains("sleep")), ~(.*60)) %>% head
```

5.5 更改列名

```
msleep %>%
  select(name, sleep_total:awake) %>%
  mutate_at(vars(contains("sleep")), ~(.*60)) %>%
  rename_at(vars(contains("sleep")), ~paste0(.,"_min")) %>% head
```

```
## 2 Owl monkey 1020 108 NA 7
## 3 Mountain beaver 864 144 NA 9.6
## 4 Greater short-tailed shrew 894 138 8.00 9.1
## 5 Cow 240 42 40.0 20
## 6 Three-toed sloth 864 132 46.0 9.6
```

保留原始数据

```
msleep %>%
  select(name, sleep_total:awake) %>%
  mutate_at(vars(contains("sleep")), funs(min = .*60)) %>% head()
```

5.6 ifelse创建2个级别的离散列

```
msleep %>%
  select(name, sleep_total) %>%
  mutate(sleep_time = ifelse(sleep_total > 10, "long", "short")) %>% head()
```

```
## # A tibble: 6 x 3
## name
                          sleep_total sleep_time
                            <dbl> <chr>
## <chr>
## 1 Cheetah
                                 12.1 long
## 2 Owl monkey
                                17 long
## 3 Mountain beaver
                                14.4 long
## 4 Greater short-tailed shrew
                                14.9 long
## 5 Cow
                                 4 short
                                14.4 long
## 6 Three-toed sloth
```

5.7 case_when创建多级离散列

此函数在后续数据清洗中有大有,需要多多练习

```
msleep %>%
  select(name, sleep_total) %>%
  mutate(sleep_total_discr = case_when(
    sleep_total > 13 ~ "very long",
    sleep_total > 10 ~ "long",
    sleep_total > 7 ~ "limited",
    TRUE ~ "short")) %>% head()
```

```
## 5 Cow 4 short
## 6 Three-toed sloth 14.4 very long
```

5.8 将数据转化为NA

```
msleep %>%
select(name:order) %>%
na_if("omni") %>% head()
```

```
## # A tibble: 6 x 4
                         genus
<chr>
## name
                                   vore order
## <chr>
                                    <chr> <chr>
                         Acinonyx carni Carnivora
## 1 Cheetah
                         Aotus <NA> Primates
## 2 Owl monkey
## 3 Mountain beaver Aplodontia herbi Rodentia
## 4 Greater short-tailed shrew Blarina <NA> Soricomorpha
## 5 Cow
                       Bos herbi Artiodactyla
                    Bradypus herbi Pilosa
## 6 Three-toed sloth
```

6. rowwise行处理函数

依然还是使用我们熟悉的iris数据集

```
iris %>% as_tibble()
```

```
## # A tibble: 150 x 5
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
       <dbl> <dbl> <dbl> <dbl> <fct>
##
                         3.5
                                       1.4
                                                    0.2 setosa
## 1
            5.1
## 2
              4.9
                           3
                                        1.4
                                                     0.2 setosa

    4.7
    3.2
    1.3

    4.6
    3.1
    1.5

    5
    3.6
    1.4

    5.4
    3.9
    1.7

    4.6
    3.4
    1.4

    5
    3.4
    1.5

    4.4
    2.9
    1.4

## 3
                                                     0.2 setosa
## 4
                                                     0.2 setosa
                                                     0.2 setosa
## 5
## 6
                                                     0.4 setosa
## 7
                                                     0.3 setosa
## 8
                                                     0.2 setosa
## 9
              4.4
                           2.9
                                        1.4
                                                     0.2 setosa
                                        1.5
              4.9 3.1
## 10
                                                     0.1 setosa
## # ... with 140 more rows
```

可以看到有5列其中一列为因子其余四列为数值,进行计算时只需要数值列

6.1 按行计算均值

方法1

```
iris %>% as_tibble() %>% select(-Species) %>%
mutate(.,mean=rowMeans(.)) %>% head()
```

根据逻辑判断只选择了数值列

```
iris %>% as_tibble() %>% select_if(is.numeric) %>%
  mutate(.,mean=rowMeans(.)) %>% head()
```

方法3

```
iris %>% as_tibble() %>% select_if(is.numeric) %>%
  rowwise() %>%
  mutate(mean = mean(c_across(Sepal.Length:Petal.Width))) %>% head()
```

```
## # A tibble: 6 x 5
## # Rowwise:
## Sepal.Length Sepal.Width Petal.Length Petal.Width mean
   ##
                     1.4
                             0.2 2.55
             3.5
      5.1
## 1
       4.9
4.7
               3
## 2
                       1.4
                              0.2 2.38
              3.2
3.1
## 3
                      1.3
                              0.2 2.35
       4.6
                       1.5
                              0.2 2.35
             3.6
3.9
       5
## 5
                      1.4
                              0.2 2.55
       5.4
                       1.7
                              0.4 2.85
## 6
```

通过**rowwise**函数说明对数据按行进行处理,c_across选择多列

方法4

```
iris %>% as_tibble() %>%
  rowwise() %>%
  mutate(mean = rowMeans(across(where(is.numeric)))) %>% head
```

```
## # A tibble: 6 x 6
## # Rowwise:
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species mean
## <dbl> <dbl> <dbl> <dbl> <dbl> <fct> <dbl>
        5.1
                3.5
                         1.4
                                  0.2 setosa 2.55
## 1
        4.7 3.2
4.6 3.1
5
        4.9
                 3
                          1.4
                                  0.2 setosa 2.38
## 2
                          3.2
3.1
3.6
## 3
## 4
## 5
        5.4
               3.9
## 6
```

通过across函数只选择了数值列,此函数异常强大,灵活使用能使代码简洁无比

6.2 按行统计最小值

```
iris %>% as_tibble() %>%
  rowwise() %>%
```

```
mutate(min = min(across(where(is.numeric)))) %>% head()
```

```
## # A tibble: 6 x 6
## # Rowwise:
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species min
##
       <dbl> <dbl> <dbl> <dbl> <dbl> <fct> <dbl>
                          1.4
                                   0.2 setosa 0.2
        5.1
                3.5
## 1
         4.9
4.7
## 2
                 3
                           1.4
                                   0.2 setosa 0.2
                 3.2
                           1.3
                                   0.2 setosa 0.2
        4.6
5
                3.1
3.6
                                   0.2 setosa 0.2
                           1.5
## 4
         5
                           1.4
                                    0.2 setosa 0.2
## 5
         5.4
                           1.7
                 3.9
                                    0.4 setosa
## 6
```

6.3 按行统计最大值

```
iris %>% as_tibble() %>%
  rowwise() %>%
  mutate(max = max(across(where(is.numeric)))) %>% head()
```

6.4 按行求和

```
iris %>% as_tibble() %>%
  rowwise() %>%
  mutate(sum = sum(across(where(is.numeric)))) %>% head()
```

```
## # A tibble: 6 x 6
## # Rowwise:
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species sum
    <dbl> <dbl> <dbl> <dbl> <fct> <dbl>
        5.1 3.5
4.9 3
                          1.4 0.2 setosa 10.2
1.4 0.2 setosa 9.5
## 1
## 2
                                     0.2 setosa
0.2 setosa
         4.7
                 3.2
3.1
                           1.3
1.5
1.4
                             1.3
                                                  9.4
## 3
          4.6
                                                  9.4
## 4
         5
                 3.6
3.9
                                      0.2 setosa 10.2
## 5
         5.4
## 6
                             1.7
                                       0.4 setosa 11.4
```

6.5 按行计算标准差

```
iris %>% as_tibble() %>%
  rowwise() %>%
  mutate(sd = sd(across(where(is.numeric)))) %>% head()
```

```
4.9 3 1.4 0.2 setosa 2.04
## 2
## 3
       4.7
              3.2
                      1.3
                             0.2 setosa 2.00
       4.6
              3.1
                      1.5
                             0.2 setosa 1.91
## 5
       5
              3.6
                      1.4
                             0.2 setosa 2.16
                      1.7 0.4 setosa 2.23
       5.4
           3.9
## 6
```

6.6 统计每行中某值出现的次数

```
iris %>% as_tibble() %>% select(-Species) %>%
mutate(.,n=rowSums(. > 3)) %>% head()
```

```
## # A tibble: 6 x 5
## Sepal.Length Sepal.Width Petal.Length Petal.Width
5.1 3.5 1.4
4.9 3 1.4
## 1
                            0.2 2
## 2
                             0.2 1
             3.2
3.1
       4.7
4.6
## 3
                      1.3
                             0.2
                      1.5
                             0.2
## 4
       5 3.6
5.4 3.9
                      1.4
                             0.2
## 5
                      1.7 0.4 2
## 6
```

7. tidyverse中的专职函数(上)

7.1 arrange()排序

• arrange 对列进行排序

```
arrange(mtcars,mpg) %>% as_tibble() %>% head()
```

```
## # A tibble: 6 x 11
## mpg cyl disp
                hp drat wt qsec vs am gear carb
## <dbl> <
## 1 10.4 8 472 205 2.93 5.25 18.0
                                 0 0 3
            460 215 3
## 2 10.4
         8
                        5.42 17.8
                                  0
                                      0
                                 0
                                     0
## 3 13.3 8 350 245 3.73 3.84 15.4
                                          3
## 4 14.3 8 360 245 3.21 3.57 15.8 0 0 3 4
## 5 14.7 8 440 230 3.23 5.34 17.4 0 0 3 4
## 6 15 8 301 335 3.54 3.57 14.6 0 1 5 8
```

arrange() 通过选定的列进行排序,默认为升序

7.2 desc()数据降序

• desc 降序排列

arrange()结合desc()对数据进行降序

```
arrange(mtcars,desc(mpg)) %>% as_tibble() %>% head()
```

```
## # A tibble: 6 x 11
## mpg cyl disp hp drat wt qsec vs am gear carb
## <dbl> <
## 1 33.9 4 71.1 65 4.22 1.84 19.9 1 1 4 1
## 2 32.4 4 78.7 66 4.08 2.2 19.5
                                   1 1
                                           4 1
## 3 30.4 4 75.7 52 4.93 1.62 18.5
                                   1 1
                                      1
## 4 30.4 4 95.1 113 3.77 1.51 16.9
                                   1
                                           5
         4 79 66 4.08 1.94 18.9
                                       1
                                           4
## 5 27.3
                                   1
                                               1
          4 120.
                 91 4.43 2.14 16.7
                                       1
## 6 26
                                   0
```

7.3 distinct()数据去重

• distinct 去重复行

```
df <- tibble(
    x = sample(10, 100, rep = TRUE),
    y = sample(10, 100, rep = TRUE))

df %>% distinct() %>% head()
```

distinct() 针对数据框进行去重, unique针对向量进行去重

7.4 rename()更改列名

• raname 更改列名

```
rename(iris,petal_length=Petal.Length) %>% as_tibble()
```

7.5 relocate()更改列顺序

• relocate 更改列的顺序

```
iris %>% as_tibble() %>% relocate(Species) %>% head()
```

```
#下述方法也可以实现,但是较为麻烦
iris %>% as_tibble() %>% select(Species, everything()) %>% head()
```

```
df <- tibble(a = 1, b = 1, c = 1, d = "a", e = "a", f = "a")
df</pre>
```

```
## # A tibble: 1 x 6
## a b c d e f
## <dbl> <dbl> <dbl> <chr> <chr> ## 1 1 1 a a a a
```

7.5.1 指定列的顺序

```
df %>% relocate(a, .after = c) %>% head()
```

```
df %>% relocate(f, .before = b) %>% head()
```

7.5.2 移至最后一列

```
df %>% relocate(a, .after = last_col()) %>% head()
```

```
df %>% relocate(ff = f) #更改列名
```

7.5.3 选择所有字符列

```
df %>% relocate(where(is.character)) %>% head()
```

```
## # A tibble: 1 x 6
## d e f a b c
## <chr> <chr> <chr> <chr> <dbl> <dbl> <dbl> <## 1 a a a 1 1 1</pre>
```

7.5.4 选择所有数字列

```
df %>% relocate(where(is.numeric), .after = last_col()) %>% head()
```

```
## # A tibble: 1 x 6
## d e f a b c
```

```
## <chr> <chr> <chr> <chr> <dbl> <dbl> <dbl> <br/> ## 1 a a a 1 1 1
```

7.6 dorp_na()删除缺失值

• drop_na

```
df <- tibble(x = c(1, 2, NA), y = c("a", NA, "b")) %>% head()
df
```

```
df %>% drop_na() %>% head()
```

```
df %>% drop_na(x) %>% head()
```

7.7 pull()提取单列

pull

pull()与\$相似,在管道中使用pull更加优雅

```
iris %>% as_tibble() %>%
  mutate(mean = rowMeans(across(where(is.numeric)))) %>%
  pull(mean) %>% head()
```

```
## [1] 2.550 2.375 2.350 2.350 2.550 2.850
```

7.7.1 点过滤

不使用pull函数称为点过滤

```
iris %>% as_tibble() %>%
mutate(mean = rowMeans(across(where(is.numeric)))) %>%
.$mean %>% head()
```

```
## [1] 2.550 2.375 2.350 2.350 2.550 2.850
```

8. tidyverse中的专职函数(中)

8.1 unite多列合并

• unite 多列合并为1列

unite 函数有5个参数

- col 设置合并后列的名称
- sep 指定分隔符
- remove 如果为TRUE,则从输出数据框中删除输入列
- na.rm 如果为TRUE,则在合并数据之前删除缺失值

上面的案例我们将2列合并成了1列,那么如果我们的数据有20列也需要2列合并为一列,此时该如何操作,请继续往下看

8.1.1 unite结合for循环合并多列

```
data <- iris %>% select_if(is.numeric)

result <- list(); b <- 2
for (i in 1:(data %>% ncol() / b)) {
    result[[i]] <- data %>%
        select((b * i - b + 1):(b * i) %>% all_of()) %>%
        unite(.,A,sep="_",remove = T,na.rm = F)
}

df <- result %>% as.data.frame() %>%
    set_colnames(c("Sepal","Petal")) %>% as_tibble()

df %>% head()
```

通过上面的for循环操作我们完成了数据的合并,这段代码还有别的用处,以后再——介绍

8.2 sperate拆分列

```
df %>% separate(`Sepal`,into=c("A","B"),sep="_") %>% head()
```

```
## # A tibble: 6 x 3
## A B Petal
## <chr> <chr> <chr> <chr> <hr> ## 1 5.1 3.5 1.4_0.2
## 2 4.9 3 1.4_0.2
## 3 4.7 3.2 1.3_0.2
## 4 4.6 3.1 1.5_0.2
## 5 5 3.6 1.4_0.2
## 6 5.4 3.9 1.7_0.4
```

8.2.1 只取分隔符前的列

```
df %>% separate(`Sepal`,into="Sepal",sep="_") %>% head()
```

```
## Warning: Expected 1 pieces. Additional pieces discarded in 150 rows [1, 2, 3, 4, ## 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, ...].
```

上面的只是一般的情况,实际中肯定有更复杂的需求,试想如果有多列需要拆分那该如果处理,请继续往下看

8.2.2 多列进行拆分

```
dt %>%
  mutate_at(vars(-Group),~str_split(.,"_",simplify=TRUE)[,2]) %>% head()
```

```
## Group A1 A2
## 1 A B D
```

```
## 2 A B D
## 3 A B D
## 4 A B D
## 5 A B D
## 6 B C A
```

8.3 sparate_rows将折叠的行展开

• separate_rows 将折叠行展开

案例1

```
df <- tibble(
    x = 1:3,y = c("a", "d_e_f", "g_h"),
    z = c("1", "2", "5"))

df</pre>
```

```
separate_rows(df,y, z,convert=TRUE,sep="_")
```

案例2

```
## a b c
## 1 1 name1,name2,name3 name7
## 2 2 name4 name8,name9
## 3 3 name5,name6 name10
```

```
d %>% separate_rows(b) %>% separate_rows(c)
```

```
## # A tibble: 7 x 3
## a b c
## <int> <chr> <chr>
## 1    1 name1 name7
## 2    1 name2 name7
## 3    1 name3 name7
```

8.3.1 for循环展开多列

```
cols <- c("b", "c")
for(col in cols) {
  d <- separate_rows_(d, col)
}
</pre>
```

另外一种展开折叠行的方法

```
df %>% rowwise() %>%
mutate(y= y %>% strsplit(.,split = "_")) %>%
unnest_longer(col = y) %>% ungroup()
```

9. tidyverse中的专职函数(下)

9.1 bind_rows数据框纵向合并

• bind_rows 纵向合并数据框

```
one <- iris[1:4, ]
two <- iris[9:12, ]
two %>% bind_rows(one) %>% as_tibble()
```

```
## 6 4.9 3 1.4 0.2 setosa
## 7 4.7 3.2 1.3 0.2 setosa
## 8 4.6 3.1 1.5 0.2 setosa
```

```
bind_rows(list(one, two), .id = "id")
```

9.2 bind_cols横向合并数据框

• bind_cols 横向合并数据框

```
bind_cols(a = 1:3, b = 4:6)
```

```
tab_1 <- mtcars[,1:3]
tab_2 <- mtcars[,4:6]
tab_3 <- mtcars[,7:8]
bind_cols(tab_1, tab_2, tab_3)</pre>
```

9.3 inner_join 内部连接

• left_join 数据框连接

合并两个数据集的变量,但仅保留具有共同ID的行

```
tab1 <- mpg %>% select(2,3)
tab1
```

```
## # A tibble: 234 x 2
## model displ
## <chr>
           <dbl>
            1.8
## 1 a4
             1.8
## 2 a4
## 3 a4
            2
            2
## 4 a4
## 5 a4
             2.8
## 6 a4
             2.8
## 7 a4
             3.1
## 8 a4 quattro 1.8
## 9 a4 quattro 1.8
## 10 a4 quattro 2
## # ... with 224 more rows
```

```
tab2 <- mpg %>% select(2,4)
tab2
```

```
## # A tibble: 234 x 2
## model year
## <chr> <int>
## 1 a4 1999
               1999
## 2 a4
              2008
## 3 a4
## 4 a4
              2008
## 5 a4
              1999
## 6 a4
               1999
         2008
## 7 a4
## 8 a4 quattro 1999
## 9 a4 quattro 1999
## 10 a4 quattro 2008
## # ... with 224 more rows
```

```
inner_join(tab1,tab2,by="model")
```

```
## # A tibble: 1,612 x 3
## model displ year
## <chr> <dbl> <int>
## 1 a4 1.8 1999
## 2 a4 1.8 1999
           1.8 2008
## 3 a4
           1.8 2008
## 4 a4
## 5 a4
           1.8 1999
## 6 a4
           1.8 1999
           1.8 2008
## 7 a4
## 8 a4
           1.8 1999
## 9 a4 1.8 1999
## 10 a4 1.8 2008
## # ... with 1,602 more rows
```

left_join保留与左数据表匹配的行

```
left_join(tab1,tab2,by="model")
```

```
## # A tibble: 1,612 x 3
## model displ year
## <chr> <dbl> <int>
## 1 a4 1.8 1999
          1.8 1999
## 2 a4
## 3 a4
         1.8 2008
         1.8 2008
## 4 a4
         1.8 1999
## 5 a4
## 6 a4 1.8 1999
## 7 a4
         1.8 2008
## 8 a4
         1.8 1999
## 9 a4
          1.8 1999
## 10 a4 1.8 2008
## # ... with 1,602 more rows
```

setequal

比较2组数据是否相同

```
setequal(1:5, 1:6)
```

```
## [1] FALSE
```

```
setequal(tab1,tab2) %>% head()
```

```
## [1] FALSE
```

10. across()列处理函数

across作为 tidyverse 中的新生函数,需要更新至 dplyr-1-0-0才能使用

across()它可以轻松地对多列执行相同的操作

across() 有两个主要参数: *第一个参数.cols选择要操作的列*第二个参数.fns是要应用于每一列的一个函数或函数列表

创建数据

```
gdf <- tibble(g = c(1,1,2,3),v1 = 10:13,v2 = 20:23,v3=1:4)
gdf %>% head()
```

10.1 给每一列加1

```
gdf %>% mutate(across(v1:v3, ~ .x +1)) %>% head()
```

10.2 前两列四舍五入

```
iris %>% as_tibble() %>%
mutate(across(c(1,2),round)) %>% head()
```

```
## # A tibble: 6 x 5
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
     <dbl> <dbl> <dbl> <dbl> <fct>
##
          5 4 1.4
5 3 1.4
5 3 1.3
5 3 1.5
5 4 1.4
5 4 1.7
                                        0.2 setosa
## 1
         5
                                1.4
## 2
                                         0.2 setosa
                                         0.2 setosa
                                          0.2 setosa
## 4
                           1.4 0.2 setosa
1.7 0.4 setosa
## 5
         5
## 6
```

还有如下2种写法

```
iris %>% as_tibble() %>%
mutate(across(1:Sepal.Width, round)) %>% head()
```

```
iris %>% as_tibble() %>%
  mutate(across(where(is.double) & !c(Petal.Length, Petal.Width), round))
```

10.3 按列求均值

```
iris %>% summarize(across(is.numeric,mean)) %>% head()
```

```
## Warning: Predicate functions must be wrapped in `where()`.
##
## # Bad
## data %>% select(is.numeric)
##
## # Good
## data %>% select(where(is.numeric))
##
## i Please update your code.
## This message is displayed once per session.
```

```
## Sepal.Length Sepal.Width Petal.Length Petal.Width
## 1 5.843333 3.057333 3.758 1.199333
```

10.4 按行求和

```
iris %>% as_tibble() %>% rowwise() %>%
mutate(mean = sum(across(where(is.numeric)))) %>% head()
```

```
## # A tibble: 6 x 6
## # Rowwise:
```

10.5 分组求均值

```
iris %>%
  group_by(Species) %>%
  summarise(across(starts_with("Sepal"), ~ mean(.x, na.rm = TRUE))) %>% head()
```

10.6 分组求和

```
iris %>%
  group_by(Species) %>%
  summarise(across(starts_with("Sepal"), ~ sum(.x, na.rm=TRUE))) %>% head()
```

```
iris %>%
  group_by(Species) %>%
  summarise(across(starts_with("Sepal"), list(mean = mean, sd = sd))) %>% head()
```

10.7 使用.name参数控制输出名

```
iris %>%
  group_by(Species) %>%
  summarise(across(starts_with("Sepal"), mean, .names = "mean_{.col}")) %>% head()
```

```
## # A tibble: 3 x 3
## Species mean_Sepal.Length mean_Sepal.Width
## <fct> <dbl> <dbl>
## 1 setosa 5.01 3.43
```

```
## 2 versicolor 5.94 2.77
## 3 virginica 6.59 2.97
```

10.8 筛选没有缺失值的行

```
starwars %>% filter(across(everything(), ~ !is.na(.x))) %>% head()
```

使用时mutate(), 所有转换across()都将立即应用

```
df <- tibble(x = 2, y = 4, z = 8)
df %>% mutate(across(everything(), ~ .x / y))
```

10.9 统计字符长度

```
starwars %>%
summarise(across(where(is.character), ~ length(unique(.x)))) %>% head()
```

10.10 统计列最小/最大值

```
min_max <- list(
    min = ~min(.x, na.rm = TRUE),
    max = ~max(.x, na.rm = TRUE)
)
iris %>% summarise(across(where(is.numeric),min_max)) %>% head()
```

11. summarise汇总数据

11.1 count()

count 统计观察次数

```
msleep %>% count(order, sort = TRUE) %>% head()
```

也可以在一个count()语句中添加多个变量

```
msleep %>% count(order, vore, sort = TRUE) %>% head()
```

11.2 summarize()

dplyr 中的summarize函数使用直观易读的代码对统计数据进行汇总

```
msleep %>%
summarise(n = n(), average = mean(sleep_total), maximum = max(sleep_total))
```

11.3 group_by()按分组进行汇总

```
msleep %>%
group_by(vore) %>%
summarise(n = n(), average = mean(sleep_total), maximum = max(sleep_total))
```

summarise()几乎适用于任何聚合函数,并允许进行额外的算术运算: * n() - 给出观察次数 * n_distinct(var) - 给出唯一值的数量 var * sum(var), max(var), min(var), ... * mean(var), median(var), sd(var), IQR(var)

将平均 sleep_total 并除以 24, 以获得一天的睡眠量

```
msleep %>%
group_by(vore) %>%
summarise(avg_sleep_day = mean(sleep_total)/24)
```

```
## 4 omni 0.455
## 5 <NA> 0.424
```

11.4 summarise_all()

summarise_all()需要一个函数作为参数,它将应用于所有列;示例代码计算每列的平均值

```
msleep %>%
group_by(vore) %>%
summarise_all(mean, na.rm=TRUE)
```

给每列的值加5

```
msleep %>%
group_by(vore) %>%
summarise_all(~mean(., na.rm = TRUE) + 5)
```

```
## # A tibble: 5 x 11
## vore name genus order conservation sleep total sleep rem sleep cycle awake
## <chr> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <
## 1 carni NA NA NA NA NA NA
                                    15.4 7.29
                                                    5.37 18.6
                                    14.5
                                           6.37
                                                    5.42 19.5
          NA NA NA
                            NA
                                    19.9 8.52
                                                    5.16 14.1
## 3 insecti
## 4 omni NA NA NA NA NA
                       NA
NA
                                                    5.59 18.1
                                  15.9 6.96
15.2 6.88
                   NA
                                                    5.18 18.8
## # ... with 2 more variables: brainwt <dbl>, bodywt <dbl>
```

11.5 summarise_if()

计算所有数字列的平均值

```
msleep %>%
  group_by(vore) %>%
  summarise_if(is.numeric, mean, na.rm=TRUE)
```

```
## # A tibble: 5 x 7
## vore sleep_total sleep_rem sleep_cycle awake brainwt bodywt
## <chr>
        <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <
## 1 carni
             10.4
                    2.29
                              0.373 13.6 0.0793 90.8
## 2 herbi
             9.51
                     1.37
                             0.418 14.5 0.622 367.
## 3 insecti
            14.9
                     3.52
                             0.161 9.06 0.0216 12.9
## 4 omni
            10.9
                     1.96
                             0.592 13.1 0.146 12.7
           10.2 1.88 0.183 13.8 0.00763 0.858
## 5 <NA>
```

11.6 rename_if()对列进行重命名

```
msleep %>%
group_by(vore) %>%
```

```
summarise_if(is.numeric, mean, na.rm=TRUE) %>%
rename_if(is.numeric, ~paste0("avg_", .))
```

11.7 summarise_at()

下面的代码将返回平均含有单词"睡眠"的所有列,并且还它们重命名为"AVG_ VAR"

```
msleep %>%
  group_by(vore) %>%
  summarise_at(vars(contains("sleep")), mean, na.rm=TRUE) %>%
  rename_at(vars(contains("sleep")), ~paste0("avg_", .))
```

11.8 top_n()

保留值最高的5个

```
msleep %>%
  group_by(order) %>%
  summarise(average = mean(sleep_total)) %>%
  top_n(5)
```

```
## Selecting by average
```

保留值最低的5个

```
msleep %>%
  group_by(order) %>%
  summarise(average = mean(sleep_total)) %>%
  top_n(-5)
```

```
## Selecting by average
```

示例代码将保留average_sleep 的5 个最高值

```
msleep %>%
  group_by(order) %>%
  summarise(average_sleep = mean(sleep_total), max_sleep = max(sleep_total)) %>%
  top_n(5, average_sleep)
```

11.9 sample_frac()

sample_frac()允许随机选择一部分行(此处为 10%)

```
msleep %>% sample_frac(.1)
```

```
## # A tibble: 8 x 11
## name genus vore order conservation sleep_total sleep_rem sleep_cycle awake
## <chr> 19.7 3.9 0.117 4.3
## 2 Africa~ Loxo~ herbi Prob~ vu 3.3 NA NA 20.7
## 3 Potto Pero~ omni Prim~ lc 11 NA NA 13
## 4 Easter~ Tami~ herbi Rode~ <NA> 15.8 NA NA 8.2
## 5 Human Homo omni Prim~ <NA> 8 1.9 1.5 16
## 6 North ~ Dide~ omni Dide~ lc 18 4.9 0.333 6
## 7 Africa~ Rhab~ omni Rode~ <NA> 8.7 NA NA 15.3
## 8 Tenrec Tenr~ omni Afro~ <NA> 15.6 2.3 NA 8.4
## # ... with 2 more variables: brainwt <dbl>, bodywt <dbl>
```